

<빅데이터와 분석 최종 레포트>

제출자: 백승욱 (보존과학과)

20251049

목차

I. 서론

II. 본론

1. 영화 선정
2. 댓글 스크래핑
3. 댓글 빈도수 분석
4. 댓글 형태소 분석
5. 댓글 감정 분석

III. 결론

I. 서론

상업성과 예술성을 모두 갖는 주제를 통해 빅데이터를 분석하고 싶었다. 주제에서 추출할 빅데이터가 있어야 했기 때문에 영화가 가장 적절할 것이라고 생각했다. 비교적 데이터량이 많은 댓글이 존재하고 영화는 평론가부터 일반인까지 나이와 성별 계층을 막론하고 다양한 사람들이 즐기기 때문에 댓글의 편향도도 다른 예술 분야에 비해 낮다고 생각했다. 이러한 이유를 종합해서 주제를 영화 댓글을 통한 손익분기점 예측으로 선정하였다. 프로젝트에선 6편의 영화를 선정해 손익분기점을 넘긴 영화와 넘기지 못한 영화 각각 3편씩의 댓글을 분석해 군집 별 많이 언급되는 단어를 통해 손익분기점을 예측하려고 한다. 지금은 총 6편의 영화이기 때문에 정확한 예측은 어려울 수

있으나 영화의 수와 댓글의 수를 최대한 많이 늘리고 분석한다면 이후에 출시되는 영화들의 손익분기점을 예측할 수 있을 것이라 믿는다. 더 나아가 영화 개봉 초기에 달리는 댓글 분석을 심도있게 진행하면 영화 공개 초반에 이와 같은 결과를 예측할 수도 있을 것 같다. 내 프로젝트는 6편의 영화를 기준에 맞추어 3편씩 나누고 왓챠피디아에 있는 영화 댓글을 모두 스크래핑하고 그 댓글들을 이용해 분석하며 프로젝트를 진행하려고 한다.

II. 본론

1. 영화선정: 공정한 프로젝트 진행을 위해 먼저 영화 선정 기준을 확실히 하였다. 일단 언어의 문제 없이 작업의 전반적인 편의성을 위해 국내 영화를 골랐고 장르별 선호도로 인해 댓글의 수나 손익분기점을 넘기고 넘기지 못하는 차이를 없애기 위해 국내에서 가장 인기있는 장르 중 하나인 '액션'을 선정하였다. 제작비 차이에 따른 손익분기점 차이도 줄이기 위해 국내 영화들의 평균 제작비를 조사했고 100억 내외(80억~120억) 규모의 영화들로 선정하였다. 또한 개봉한 연도의 차이가 너무 클 경우 제작비의 가치나 사람들의 영화에 대한 관심 차이가 있을 수 있겠다 판단하여 2021~2023에 개봉된 영화들로 선정하였다. 요약하자면 국내 액션 장르 제작비 100억 내외의 2021~2023 사이에 개봉한 영화들로 기준 별 3편씩 총 6편 선정하였다. 손익분기점을 넘긴 영화로 선정한 것들은 유체이탈자(제작비 약 120억 개봉연도 2021), 인질 (제작비 약 80억 개봉연도 2021), 헌트 (제작비 약 120억 개봉연도 2022)이다. 손익분기점을 넘기지 못한 영화로 선정한 것들은 특송 (제작비 약 80억 개봉연도 2022), 데시벨 (제작비 약 100억 개봉연도 2022), 귀공자 (제작비 약 100억 개봉연도 2023)이다.

2. 댓글 스크래핑: 각 영화의 댓글을 왓챠피디아 댓글창에서 전체 스크롤을 통해 스크래핑한다. 코드를 구성하기 어려워 제미나이에게 처음부터 도움을 받았다. 처음엔 로그인에 문제가 생겨 코드를 수정했고 다음엔 사이트 접근에 문제가 생겨 교수님에게 도움을 받았다. 이후에 스크래핑 스크롤 횟수가 부족해 99999번 정도로 수정해나가며 끝까지 스크롤을 가능하게 하였다. 그리고 영화별로 스크래핑이 되는 영화가 있고 안 되는 영화가 있어 중간 중간 코드를 수정하며 모든 영화의 댓글을 스크래핑을 완료했다. '헌트'의 경우 스크래핑이 계속 되지 않았는데 교수님의 도움을 받아 스크래핑을 진행하긴 했지만 엑셀 파일로 다운로드가 되지 않아 이후 프로젝트엔 적용하지 못했다...



<그림 1>: 스크래핑 코드 1번째(직접)



<그림 2>: 스크래핑 코드 2번째(직접)



<그림 3>: 스크래핑 코드 3번째(직접)



<그림 4>: 스크래핑 코드 수정(교수님)

완성된 코드로 영화 별로 스크래핑을 진행했고 손익분기점을 넘은 영화들 유체이탈자: 900개, 인질: 2241개, 힌트: 3507개 스크래핑했다. 손익분기점을 넘지 못한 영화들 특송: 1072개, 데시벨: 941개, 귀공자: 1372개 스크래핑했다.



<그림 4>: 힌트 댓글 스크래핑



<그림 5>: 댓글 스크래핑 엑셀 정리

3. 댓글 빈도수 분석: 기준별 댓글의 군집에서 반복되는 키워드를 통해 특정 키워드가 댓글에서 반복되면 그것을 통해 손익분기점을 예측하려고 했기 때문에 각 영화의 댓글에서 키워드의 빈도를 분석할 수 있는 코드를 만들었다. 이 코드 또한 제미나이의 도움을 받아 제작하였고 처음 오류는 한글 글씨체 설정에서 오류가 계속 발생해 수정하였고 파일을 업로드 할 때 엑셀 파일 자체로 업로드하려고 했으나 코랩에서 오류가 발생해 엑셀 xlsx 파일로 변환하여 진행할 수 있게 코드를 수정하였다. 그리고 빈도수를 확인할 수 있는 방법으로 워드 클라우드 식을 선정해 진행하였으나 워드 클라우드의 형태는 확실하게 어떤 키워드가 얼마만큼의 수만큼 반복되는지 볼 수 없고 가장 많이 반복된 키워드부터 내림차순으로 볼 수 없어 가독성의 문제가 있다고 판단하였다. 이를 해결하기 위해 결과 산출 방식을 워드 클라우드에서 내림차순 막대 그래프로 수정했으나 빈도 분석에선 한글이 정확히 산출되는 반면 막대 그래프에선 한글이 깨지는 문제가 계속 발생해 막대 그래프 대신 내림차순으로 키워드와 그 키워드의 빈도 반복 순을 볼 수 있는 형태로 수정하여 최종 진행하였다.

크기	: 20회
조금	: 20회
역할	: 20회
소재	: 20회
없고	: 20회
평가	: 20회
아쉽다	: 20회
보기	: 19회
경찰	: 19회
역시	: 19회
문제	: 18회
인상	: 18회

<그림 6,7>:댓글 내에서 반복되는 키워드를 정리하고 그 빈도수를 나타내게 하였다.

총, 추출된 단어 개수: 9,280개
중복, 제거된 단어 개수: 3,688개

황정민	: 1303회
남치	: 235회
인질	: 233회
결정	: 192회
물집	: 125회
경찰	: 114회
소재	: 104회
없는	: 97회
실제	: 94회
전개	: 92회
긴장감	: 90회
같은	: 87회
있는	: 82회
없이	: 72회
상황	: 69회
스릴러	: 69회
포함	: 69회
상대	: 67회
뿐만	: 66회
인물	: 64회
각각	: 64회


4. 댓글 형태소 분석: 빈도수를 분석할 때 함께 적용한 부분이다. 빈도수와 형태소를 한 번에 추출할 코드를 짜야 했기 때문에 이것도 제미나이의 도움을 많이 받아 작성하였다. 영화에 대한 선호도를 나타내는 단어를 위주로 수집하고 싶었기 때문에 가장 처음엔 형용사만을 추출하였다. 수집 결과를 보다보니 형용사만을 수집해 분석하기엔 무리가 있다고 판단하여 명사도 추가적으로 스크래핑하였다. 하지만 명사, 형용사만으로 영화에 대한 선호도를 판단할 수 없었고 영화 종류별로 불용어가 너무 제각각에 그 수도 많아 거르는 작업이 잘 되지 않았다. 처음엔 형용사만 그리고 명사, 형용사만으로 선호도를 판단할 수 있을 것이라고 생각했기 때문에 두 개만으로 분석이 어렵다고 판단한 후에도 어떤 단어를 더 추출하고 제거해야 할지 방향을 잡지 못했다.



<그림 8,9 >: 형태소 분석 알고리즘



5. 댓글 감정 분석: 이 코드도 처음은 제미나이에게 도움을 다 받아 작성하였거 이후 오류 해결을 위해 교수님의 도움을 받았다. 마지막 분석에서 밝히지만 파일을 로컬 컴퓨터에서 업로드 하는 방식이 편해 모두 코드를 그렇게 구성하였고 교수님의 도움을 받은 코드들도 모두 진행 전에 파일 업로드 방식을 수정하는 과정을 거쳤다.



<그림10>: 엑셀 업로드 방법 변경



<그림11,12> 댓글 감정분석과 정리 파일

IV. 결론

프로젝트를 마무리하는 고찰이나 이후 진행한다면 어떻게 수정하면 좋을지 어떤 것을 보완해야 할 지를 생각해보았다. 우선 스크래핑 과정에서 왓챠피디아에는 스포일러를 포함하고 있는 댓글은 ‘스포일러’를 포함하고 있습니다’와 같은 문구가 먼저 뜬다. 이것을 변환해 진짜 댓글 내용을 스크래핑하는 과정이 필요했는데 없었다. 이 문제는 스크래핑에선 인식하지 못했고 빈도 분석에서 문제를 알게 되었는데 많이 반복된 댓글부터 내림차순으로 정리해 보다보니 스포일러라는 단어가 유독 많았고 수집된 댓글 파일을 보다보니 이와 같은 문제가 있었다는 것을 알게 되었다. 이후에 진행할 때에는 스포일러로 가려진 부분을 드러내고 완전한 댓글 내용을 스크래핑 하는 과정이 필요할 것 같다. 형태소 분석 같은 경우는 진행하기 전 예측으로 형용사만으로 영화에 대한 선호도를 알 수 있을 것 같았는데 예측에서 벗어났다. 명사를 추가하면 될 것 같았는데 그래도 직접적인 선호도를 반영할 순 없어서 어떤 단어를 추출해야 하는 지를 끝내 다시 설정하지 못했다. 추출뿐 아니라 불용어 제거에서도 문제가 있었다. 영화는 작품명이나 배우의 이름이 많이 언급되는데 이와 같은 것 뿐만 아니라 영화 별로 설정해줘야 하는 불용어들의 수와 종류가 너무 많아 분류가 잘 이루어지지 않았다. 감정 분석은 프로젝트에서 가장 목적성이 모호한 분석이 되었는데 코드를 구성하고 계속 진행하다 보니 감정 분석은 문장 단위로 해야 하는 분석인데 내 프로젝트는 영화의 키워드를 추출해 그것을 통해 결과를 산출하려고 한 것이었기 때문에 어울리지 않고 꺾다놓은 보릿자루 같았다. 다시 진행한다면 제거하거나 다른 방향으로 활용할 수 있게 해야 할 것 같다고 느꼈다. 마무리 해보자면 처음 진행하는 컴퓨터 과제였다. 한글을 쓰는 것도 익숙하지 않고 다 낯설어서 힘들었다. 그래도 듣고 싶었고 흥미를 갖고 선택한 수업이라 프로젝트를 진행하는 과정이 즐거웠다. 코랩을 쓰는 것도 어색해 거의 다 교수님의 도움을 받아 작성했지만 그저 이 과정들이 내가 컴퓨터와 더 친해지고 열정을 갖게 해준 계기가 된 것 같아 기뻐다. 처음 프로젝트를 기획할 땐 이것을 통해 손익분기점을 예측할 수 있는 프로그램을 만들고 싶었지만 결론적

으론 실패했다. 하지만 진행하며 얻은 고충들과 수정사항들을 보완하고 진행한 후에
영화와 댓글의 수를 늘려 적용한다면 처음 의도한 결과를 얻을 수 있을 것이라고 확
신한다. 끝으로 친하지 않은 컴퓨터와 한 학기동안 사투를 버린 시간이 큰 도움이 됐
고 나중엔 더 큰 도움이 될 것 같아 기대된다. 한 학기동안 큰 도움을 주신 교수님께
게 감사드린다는 말씀 꼭 드리고 싶다.

감사합니다 교수님 한 학기동안 많은 도움 받으며 정말 감사했습니다!!!

-보존과학과 백승욱 올림-